



UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Informatica

Corso di Laurea Triennale in Informatica

TESI DI LAUREA

Modelli di Machine Learning Interpretabili per la Previsione della Glicemia nel Diabete di Tipo 1

RELATORE

Prof. Fabio Palomba

Università degli Studi di Salerno

CANDIDATO

Giovanni Cerchia

Matricola: 0512120818

Anno Accademico 2024-2025

Questa tesi è stata realizzata nel

sesa^{lab}
SOFTWARE ENGINEERING
SALERNO

Abstract

Il diabete di tipo 1 (T1D) è una patologia autoimmune che richiede monitoraggio continuo e decisioni terapeutiche tempestive. La previsione a breve termine della glicemia può supportare il dosaggio dell'insulina e prevenire eventi di ipo- e iperglicemia. L'avvento dei sensori di Continuous Glucose Monitoring (CGM) ha ampliato la disponibilità di dati, fornendo serie temporali di misurazioni su cui addestrare modelli predittivi. Questo lavoro analizza un dataset reale proveniente da uno studio dell'Ospedale Universitario San Cecilio di Granada e introduce una pipeline riproducibile che comprende preprocessing, preparazione dei dati, addestramento e confronto tra modelli di machine learning tradizionale e reti neurali, con enfasi sulle architetture ricorrenti LSTM e GRU. Le prestazioni, valutate con metriche standard MAE e RMSE e convalidate clinicamente mediante la Clarke Error Grid, evidenziano: una capacità predittiva lievemente superiore delle reti neurali rispetto ai metodi tradizionali; benefici non sistematici della personalizzazione, intesa come l'addestramento su dati CGM del singolo paziente, con il modello generale più pratico e di facile adozione; spiegazioni XAI con SHAP coerenti con la fisiologia, utili a migliorare l'interpretabilità e la fiducia clinica. Il lavoro propone un flusso sperimentale riproducibile e allineato allo stato dell'arte.

Indice

Elenco delle Figure	iii
Elenco delle Tabelle	v
1 Introduzione	1
1.1 Contesto Applicativo	1
1.2 Motivazioni e Obiettivi	2
1.3 Risultati Ottenuti	3
1.4 Struttura della Tesi	3
2 Background e Stato dell'Arte	5
2.1 Approcci di forecasting per serie temporali	5
2.1.1 Approccio classico	5
2.1.2 Machine learning tradizionale (TML)	6
2.1.3 Reti neurali artificiali (ANN)	6
2.2 Input univariato e multivariato	7
2.3 Panorama dei dataset	7
2.4 Explainability nel forecasting glicemico	9
2.5 Lavori correlati	9
2.5.1 Limiti dei lavori precedenti affrontati	12

3	Metodo di Ricerca	13
3.1	Obiettivo generale e Domande di Ricerca	13
3.1.1	Panoramica del processo sperimentale	15
3.2	Esplorazione preliminare del dataset	16
3.2.1	Distribuzione dei valori glicemici	17
3.2.2	Dipendenza temporale	18
3.3	Preparazione dei dati	20
3.3.1	Rimozione degli outlier	20
3.3.2	Resampling	22
3.3.3	Campionamento minimo per l'addestramento	24
3.3.4	Preparazione delle finestre scorrevoli	24
3.3.5	Feature scaling	25
3.4	Valutazione preliminare dei modelli	26
3.4.1	Modelli considerati	26
3.4.2	Architetture ANN scelte	29
3.4.3	Metriche di valutazione statistiche	30
3.4.4	Valutazione clinica: la Clarke Error Grid	31
3.4.5	Addestramento e valutazione	32
3.5	Addestramento con più feature	34
3.6	Ottimizzazione dei modelli	36
3.6.1	Modelli di gradient boosting	36
3.6.2	Reti neurali ricorrenti	37
4	Analisi dei Risultati	39
4.1	Prestazioni delle ANN rispetto agli algoritmi TML	39
4.2	Prestazioni dei modelli generali rispetto ai personalizzati	42
4.3	Interpretabilità con SHAP: evidenze globali e locali	45
5	Conclusioni	50
5.1	Risultati principali e impatto del lavoro	50
5.2	Limiti e sviluppi futuri	51
	Bibliografia	53

Elenco delle figure

2.1	Valore RMSE ottenuto per differenti HL. Fonte: [1]	10
2.2	Architetture dei modelli addestrati in [1].	11
3.1	Overview dei passi principali condotti per rispondere alle RQ.	15
3.2	Distribuzione delle misurazioni per il dataset <i>T1DiabetesGranada</i> .	17
3.3	Box plot per 10 pazienti scelti casualmente.	18
3.4	Funzione di autocorrelazione (ACF) per i pazienti <i>LIB193555</i> e <i>LIB193645</i> .	19
3.5	Funzione di autocorrelazione parziale (PACF) per i pazienti <i>LIB193457</i> , <i>LIB193486</i> , <i>LIB193482</i> e <i>LIB193446</i> .	20
3.6	Distribuzione delle misurazioni glicemiche: generale; per sesso; per età. Fonte: [2]	21
3.7	Casi rappresentativi su cui è stato applicato il downsampling.	23
3.8	Esempio di costruzione delle finestre scorrevoli per una HL di 4 campioni (1 ora) e un PH di 2 campioni (0,5 ore), con passo unitario.	25
3.9	Architetture dei modelli ANN considerati.	29
3.10	Visualizzazione della Clarke Error Grid vuota.	32
3.11	Distribuzione per condizione clinica dei dati nei set.	33
3.12	Distribuzione del numero di record dei parametri biochimici. Fonte: [2]	34
3.13	Importanza delle categorie di feature per il modello XGBoost standard.	36

4.1	Visualizzazione della Clarke Error Grid per i modelli generali.	41
4.2	Strategia di suddivisione per l'addestramento dei modelli personalizzati.	43
4.3	CEG a confronto per paziente e strategia di addestramento.	45
4.4	Valore SHAP medio per feature per i due modelli rappresentativi. . .	47
4.5	Summary Plot per i due modelli rappresentativi.	48
4.6	Waterfall Plot di GRU per tre casi clinici: iper-, normo- e ipoglicemia.	49

Elenco delle tabelle

3.1	Riepilogo dei parametri di addestramento delle ANN.	30
3.2	Prestazioni cumulative dei modelli valutati sul validation set.	33
3.3	Prestazioni cumulative del modello XGB standard sul sottoinsieme costruito.	35
3.4	Spazi di ricerca per il tuning di LightGBM e XGBoost.	37
3.5	Prestazioni cumulative dei modelli ottimizzati.	37
3.6	Range di parametri esplorati per i modelli ricorrenti (LSTM/GRU). .	38
4.1	Prestazioni cumulative dei due modelli rappresentativi.	40
4.2	Prestazioni per condizione glicemica.	40
4.3	Distribuzione delle inferenze nelle regioni della Clarke Error Grid. .	41
4.4	Migliore e peggiore valutazione per il modello GRU sul test set. . . .	42
4.5	Prestazioni del modello generale e personalizzato per i due pazienti considerati.	43
4.6	Distribuzione delle inferenze nelle regioni CEG per il paziente <i>LIB193939</i> . .	44
4.7	Distribuzione delle inferenze nelle regioni CEG per il paziente <i>LIB194117</i> . .	44

CAPITOLO 1

Introduzione

1.1 Contesto Applicativo

Il diabete mellito è un insieme di patologie metaboliche caratterizzate da un'elevata concentrazione di glucosio nel sangue (iperglicemia), conseguente a un difetto nella secrezione o nell'azione dell'insulina. Nel diabete di tipo 1 (T1D) il sistema immunitario attacca e distrugge le cellule β del pancreas, responsabili della produzione di insulina. Il paziente deve quindi monitorare costantemente la glicemia e somministrarsi insulina esogena per evitare sia episodi acuti di ipo- e iperglicemia (potenzialmente letali) sia complicanze croniche (neuropatie, retinopatie, nefropatie, malattie cardiovascolari) che compromettono qualità e aspettativa di vita.

Negli ultimi anni i sensori per il monitoraggio continuo del glucosio hanno rivoluzionato la gestione del T1D. I sistemi di *Continuous Glucose Monitoring* (CGM) forniscono misurazioni frequenti e quasi in tempo reale, consentendo l'identificazione rapida delle tendenze e l'automazione di sistemi di controllo dell'insulina. Queste tecnologie hanno anche ampliato la base di dati disponibile, favorendo lo sviluppo di algoritmi predittivi a supporto di pazienti e clinici nelle decisioni terapeutiche.

Nel forecasting glicemico si ricorre principalmente a due famiglie di algoritmi [3]:

- i metodi di *traditional machine learning* (TML), come regressione, alberi decisionali e gradient boosting, richiedono meno dati e risorse computazionali, si addestrano più rapidamente e offrono maggiore trasparenza;
- le *artificial neural networks* (ANN), in particolare le architetture con unità ricorrenti, sono efficaci nel modellare fenomeni complessi e dipendenze temporali, a fronte di un costo computazionale più elevato e di una minore comprensibilità del processo decisionale che conduce alla previsione.

In ambito clinico la trasparenza dei modelli predittivi, spesso percepiti come *black box*, riveste un ruolo centrale: medici, pazienti e sviluppatori devono poter comprendere e giustificare le raccomandazioni [4]. Le tecniche di *Explainable AI* (XAI), come SHAP e LIME, sono state introdotte per migliorare la leggibilità delle predizioni dei modelli.

Tuttavia, la letteratura si è concentrata soprattutto su compiti di classificazione di eventi ipo- o iperglicemici, mentre l'interpretabilità di modelli di regressione che stimano il valore glicemico futuro è meno indagata. Questa esigenza motiva le scelte e gli obiettivi di questo studio, descritti nella sezione seguente.

1.2 Motivazioni e Obiettivi

La previsione a breve termine della glicemia può ridurre il carico decisionale dei clinici e prevenire deviazioni della glicemia dal range euglicemico ritenuto sicuro; tuttavia, nei contesti reali rimane aperta la ricerca di un equilibrio tra accuratezza, praticabilità d'uso e trasparenza dei modelli impiegati.

Questa tesi si propone di sviluppare e valutare una pipeline riproducibile sul dataset longitudinale *T1DiabetesGranada* per la previsione glicemica con orizzonte di 30 minuti ed è guidata da tre obiettivi principali:

1. valutare se e in che misura la maggiore complessità delle reti neurali offra reali vantaggi in termini di accuratezza rispetto ai modelli di machine learning tradizionale;
2. studiare i risultati ottenuti da un modello addestrato sui dati di più soggetti (modello *generale*) e da uno addestrato sui dati di ciascun paziente (modello

personalizzato), quantificando l’impatto della variabilità inter-paziente sulla qualità delle previsioni;

3. integrare tecniche di XAI per rendere trasparenti le decisioni dei modelli e verificarne la coerenza con la fisiologia.

In sintesi, si intende proporre una pipeline predittiva accurata e interpretabile, semplice da distribuire, insieme a evidenze empiriche e strumenti di analisi che ne facilitino l’adozione in contesti reali.

1.3 Risultati Ottenuti

Nel confronto tra un modello di machine learning tradizionale ottimizzato e una rete neurale ricorrente si è osservato un vantaggio lieve a favore della rete ricorrente; tale margine, tuttavia, non è sufficiente a compensare la maggiore complessità, i costi di addestramento e la gestione operativa, e non ne giustifica l’adozione preferenziale in scenari reali.

L’analisi tra modelli generali e personalizzati ha mostrato che la personalizzazione non è sempre vantaggiosa: in presenza di soggetti e condizioni favorevoli può produrre guadagni, ma in media il modello generale offre nuovamente il miglior compromesso tra accuratezza e praticabilità d’uso.

Infine, le tecniche di XAI applicate hanno fornito spiegazioni globali e locali coerenti con la fisiologia: le previsioni si basano prevalentemente sul livello glicemico corrente e sul trend recente; tali evidenze risultano stabili e interpretabili nelle diverse fasce glicemiche, migliorando trasparenza e fiducia negli utilizzatori.

1.4 Struttura della Tesi

Il resto della tesi è organizzato come segue:

- **Capitolo 2 – Background e Stato dell’Arte:** presenta i principali approcci al forecasting glicemico descritti in letteratura, i dataset più utilizzati, le tecniche di explainability e i lavori correlati che hanno adottato lo stesso dataset di questo studio; evidenzia infine i limiti riscontrati che si intendono affrontare.

- **Capitolo 3 – Metodo di Ricerca:** introduce le Domande di Ricerca e offre una visione d'insieme del processo sperimentale; descrive poi l'esplorazione del dataset *T1DiabetesGranada*, la progettazione della pipeline di machine learning, gli aspetti teorici dei modelli e delle metriche adottate, e riporta i risultati della valutazione preliminare.
- **Capitolo 4 – Analisi dei Risultati:** presenta e discute i risultati dei tre esperimenti condotti, finalizzati a fornire risposte alle domande di ricerca.
- **Capitolo 5 – Conclusioni:** sintetizza i risultati conseguiti e il loro impatto, e discute i possibili sviluppi futuri.

Background e Stato dell'Arte

Questo capitolo inquadra il problema della previsione della glicemia nel contesto scientifico, offrendo un panorama essenziale di metodi e dati utilizzati in letteratura. Nelle sezioni seguenti si presentano i principali approcci di forecasting per le serie temporali, i dataset più impiegati per la previsione glicemica e le tecniche di Explainable Artificial Intelligence (XAI), ponendo le basi per le scelte metodologiche adottate nel resto della tesi.

2.1 Approcci di forecasting per serie temporali

2.1.1 Approccio classico

Storicamente, i metodi statistici sono stati i più utilizzati per il forecasting della glicemia; tra questi, i modelli *ARIMA*, derivati dalla famiglia *ARMA* introdotta da Hermann Wold negli anni '30. Tali modelli stimano il valore futuro combinando valori passati (componente *AutoRegressive*) ed errori recenti (componente *Moving Average*). Poiché richiedono serie stazionarie — prive di trend e stagionalità — si applica la differenziazione: si eseguono d differenze tra osservazioni consecutive,

quindi si addestra un modello ARMA sulla serie trasformata e, infine, si riporta la previsione alla scala originale.

In letteratura, ARIMA ha mostrato risultati solidi nel tempo. In [5] Yang et al. propongono una versione "adattiva" che stima i parametri p , d e q a ogni istante mediante il criterio AIC, riducendo i falsi allarmi di ipoglicemia a 30 minuti rispetto a un modello con parametri fissi. In un confronto diretto su 30 algoritmi di apprendimento automatico, con lo stesso dataset e orizzonte di previsione a 30 minuti, Prendin et al. riportano in [6] un RMSE pari a 22.15 mg/dL per un ARIMA personalizzato, comparabile alla migliore rete neurale feed-forward valutata nello studio (21.52 mg/dL).

2.1.2 Machine learning tradizionale (TML)

In continuità con gli approcci statistici, si sono affermati i modelli di machine learning "tradizionali". Tra questi, le *Support Vector Machines* (SVM) sono tra i più studiati [3]; la variante più usata è la *Support Vector Regression* (SVR), spesso con kernel RBF e abbinata a procedure di feature selection [7].

Bunescu et al. propongono in [8] un approccio "ibrido" in cui un modello fisiologico genera feature informative per uno SVR personalizzato. Lo studio, condotto sul dataset *OhioT1DM*, mostra che lo SVR così configurato supera sia un modello ARIMA sia la stima di tre esperti clinici nelle previsioni a 30 e 60 minuti. Sebbene meno utilizzati, anche altri modelli risultano competitivi: in [9] *Random Forest* supera modelli logistici con regolarizzazione L1 e reti neurali nella predizione di eventi ipoglicemici notturni; van Doorn et al., in [10], evidenziano inoltre buona accuratezza e alta *clinical safety* di RF nella previsione glicemica su soggetti con diabete di tipo 2, suggerendo una possibile trasferibilità dei risultati a soggetti con diabete di tipo 1.

2.1.3 Reti neurali artificiali (ANN)

Negli ultimi anni, la letteratura si è orientata verso l'impiego di reti neurali artificiali, in particolare reti ricorrenti, per il forecasting glicemico.

Il principale limite delle reti ricorrenti è il problema dei *vanishing* o *exploding gradients*, che si verifica quando i gradienti diventano estremamente piccoli o grandi

durante la *backpropagation*, impedendo l'apprendimento o rendendolo instabile [11]. Tra le soluzioni figura l'uso di celle *Long Short-Term Memory* (LSTM), ampiamente adottate in letteratura [12, 13, 14, 15] fino a diventare uno standard di riferimento nei problemi di previsione glicemica.

2.2 Input univariato e multivariato

La scelta dell'input — *univariato* (con solo misurazioni CGM) o *multivariato* (con misurazioni CGM e altre variabili esogene) — è un elemento cruciale per categorizzare gli algoritmi di previsione della glicemia.

Diversi studi indicano che l'uso esclusivo dei dati raccolti dai sensori CGM ne facilita l'adozione pratica in contesti clinici reali, poiché riduce lo sforzo di acquisire dati da molteplici sensori, elaborarli e integrarli, tenendo conto di modalità e frequenze di campionamento differenti. Di conseguenza, numerosi lavori hanno esplorato modelli basati esclusivamente sulle serie CGM [16, 17, 18]. Altri contributi mostrano invece che variabili esogene — come i carboidrati ingeriti, il bolo insulinico somministrato e l'attività fisica svolta — possono migliorare le prestazioni, motivando l'uso di modelli che assumono in input serie temporali multivariate [10, 19, 20].

Il confronto diretto tra i diversi tipi di input rimane tuttavia limitato e con esiti non univoci. Zecchin et al. [21] hanno riportato benefici dall'aggiunta di carboidrati ingeriti e bolo insulinico su orizzonti temporali tra 30 e 120 minuti con una rete neurale; anche Nordin et al. [22], utilizzando un modello LSTM, osservano un vantaggio dell'approccio multivariato rispetto a quello univariato. Al contrario, Hameed et al. [23] evidenziano che l'inclusione di carboidrati e bolo insulinico può introdurre perturbazioni che non sempre si traducono in un miglioramento dell'accuratezza della previsione glicemica finale.

2.3 Panorama dei dataset

In letteratura, i dataset utilizzati per la previsione della glicemia si collocano in due categorie:

1. *simulati* (o *sintetici*), con dati generati al calcolatore, tra cui il *UVA/Padova T1D* [24] è il riferimento più diffuso;
2. *clinici* (dati real-world), con dati raccolti su soggetti umani con diabete mellito tramite sensori CGM o altri dispositivi indossabili, come i microinfusori di insulina.

Studi su dataset in silico mostrano spesso risultati, in termini di accuratezza, migliori rispetto a quelli condotti su dati realmente raccolti. Questi ultimi, infatti, includono informazioni più eterogenee e rumorose, con misurazioni mancanti, irregolari o ritardate, ma riflettono meglio le condizioni cliniche reali dell'andamento glicemico.

Secondo la revisione di Felizardo et al. [25], il dataset *OhioT1DM* [26] è il più utilizzato in letteratura tra quelli clinici pubblicamente accessibili. Comprende due coorti di soggetti con diabete di tipo 1: il dataset della prima coorte (*Ohio_2018*, 6 soggetti) è stato rilasciato nel 2018 in occasione della prima *BGL Prediction Challenge* [27]; quello della seconda coorte (*Ohio_2020*, ulteriori 6 soggetti) è stato rilasciato nel 2020 per la seconda edizione della stessa sfida [28]. Complessivamente i partecipanti sono 5 donne e 7 uomini, con età compresa tra 20 e 80 anni al momento della raccolta. I partecipanti allo studio hanno utilizzato un microinfusore, un sensore CGM e una fitness band. Oltre ai sensori fisiologici, ciascun soggetto ha riportato le stime dei carboidrati ingeriti (*Carb*) e del bolo insulinico iniettato (*Bolus*). La raccolta ha coperto 8 settimane per soggetto, con gli ultimi 10 giorni riservati al set di valutazione.

Un altro dataset ampiamente utilizzato è *DiaTrend* [29], che comprende più di 27 000 giorni di misurazioni da sensori CGM e oltre 8 000 giorni da microinfusori. I partecipanti allo studio includono 54 soggetti con diabete di tipo 1, di età compresa tra 25 e 74 anni.

Recentemente, Rodriguez Leon et al. hanno introdotto *T1DiabetesGranada* [2], uno dei più ampi dataset longitudinali e aperti per la ricerca sul T1D, con 257 780 giorni di misurazioni CGM raccolte da 736 pazienti nell'arco di quattro anni. L'obiettivo è affrontare la tipica scarsità di dati nella ricerca sulla previsione glicemica, facilitando lo sviluppo di modelli più robusti e accurati.

2.4 Explainability nel forecasting glicemico

L'adozione di tecniche di Explainable Artificial Intelligence (XAI) è cruciale per trasferire i modelli di previsione glicemica dalla ricerca alla pratica clinica. Tra i vari metodi, SHAP (*SHapley Additive ExPlanations*) si è affermato come approccio teoricamente fondato e *model-agnostic*, capace di fornire spiegazioni sia a livello globale (sull'intero set di dati) sia a livello locale (sulle singole previsioni), mostrando come ciascuna feature influenzi il risultato.

In [30], Annuzzi et al. impiegano SHAP per chiarire il ruolo di diversi fattori nutrizionali — energia assunta, carboidrati, proteine, lipidi, acidi grassi, fibre, indice e carico glicemico — rispetto alle sole feature derivate dalle misurazioni glicemiche, considerando reti neurali artificiali e diversi orizzonti di previsione. In [31], l'analisi con SHAP consente di distinguere chiaramente il comportamento appreso da due modelli LSTM con accuratezza simile: emerge quando la rete apprende relazioni coerenti (ad esempio, le iniezioni di insulina favoriscono una diminuzione della glicemia, mentre i carboidrati ingeriti ne causano un aumento) e quando, invece, apprende le stesse relazioni ma in senso inverso, motivando così la scarsa affidabilità clinica degli output del secondo modello.

2.5 Lavori correlati

Durante la revisione della letteratura è emerso un contributo rilevante per la presente tesi: la tesi di dottorato di Rodriguez Leon [1], nella quale viene introdotto ed esplorato il dataset *T1DiabetesGranada*. Si tratta, ad oggi, del primo lavoro che utilizza questo dataset per costruire modelli regressori di previsione della glicemia, ponendo quindi basi metodologiche per studi successivi sullo stesso dataset.

La tesi confronta tre famiglie di modelli — generali, personalizzati e basati su gruppi — condividendo la stessa pipeline di preprocessing e preparazione dati. Questa fase consiste nella costruzione degli input sotto forma di finestre scorrevoli con passo di 1 campione. Ogni finestra comprende 8 campioni (circa 2 ore di storia) e il modello prevede un unico valore futuro (*single-output*) per ciascuno dei seguenti orizzonti: 30, 60, 90, 120, 180 e 240 minuti. Il numero di campioni che compongono le

finestre è definito *history length* (HL) ed è stato scelto tramite un processo di tuning che ha previsto l'addestramento di un modello ricorrente per 10 epoche su più valori di HL: da un minimo di 30 minuti (2 campioni) fino a 3 ore e mezza (14 campioni). I risultati sono mostrati in Figura 2.1.




Figura 2.1: Valore RMSE ottenuto per differenti HL. Fonte: [1]

I tre modelli valutati sono: un modello lineare, assunto come *baseline* per il confronto, una rete ricorrente (RNN) con unità LSTM e una rete convoluzionale (CNN). Per l'addestramento è stata utilizzata la libreria TensorFlow; le architetture dei primi due modelli sono mostrate in Figura 2.2 e replicano quelle di uno studio presentato durante la seconda *Blood Glucose Level Prediction Challenge* [28], classificatosi tra le prime posizioni. La valutazione è stata eseguita combinando metriche statistiche (RMSE, MSE, MAE e MAPE) e la Clarke Error Grid (CEG) come metrica clinica, sia sull'intero intervallo dei valori glicemici sia sui range clinicamente rilevanti di ipo- e iperglicemia.

Nel complesso, i modelli lineari scelti come baseline risultano lievemente migliori di LSTM e CNN, verosimilmente perché la maggior parte dei dati ricade nel range [100, 200] mg/dL [1]. Di contro, sono anche quelli più inclini a produrre previsioni fuori dal range realistico [0, 500] mg/dL, mentre i modelli non lineari si sono dimostrati più robusti. Al di là dei numeri, l'analisi conferma l'importanza




Figura 2.2: Architetture dei modelli addestrati in [1].

di una valutazione olistica che includa metriche cliniche, statistiche e analisi per sotto-intervalli, al fine di evitare conclusioni fuorvianti.

Interessante è anche l’approccio basato su gruppi. A partire dalle sole serie CGM, vengono estratte feature semplici — media, deviazione standard, minimo e massimo — calcolate in diverse fasce orarie (*early morning, morning, noon, afternoon, night*). Su tali feature sono applicati diversi algoritmi non supervisionati (*K-means, GMM, clustering gerarchico* e *SOM*). Le soluzioni vengono confrontate mediante *Rand Index* e, all’interno di ciascun raggruppamento, si seleziona quella con il miglior *Silhouette Coefficient*. In conclusione, sono stati ottenuti 6 gruppi distinti, utili per addestrare altrettanti modelli di previsione. Una volta addestrati, questi modelli possono essere applicati a nuovi soggetti dopo una rapida assegnazione al gruppo di appartenenza.

Sul piano delle prestazioni, i modelli group-based superano quelli generali in diversi cluster e condizioni — soprattutto per i pazienti con miglior controllo glicemico — e il loro vantaggio cresce per orizzonti più lunghi, segno che catturano meglio pattern a medio-lungo termine. I modelli personalizzati, invece, non prevalgono sistematicamente né sui generali né sui group-based.

2.5.1 Limiti dei lavori precedenti affrontati

La letteratura di riferimento più vicina al presente lavoro [1] ha esplorato principalmente architetture neurali, trascurando approcci non basati su ANN. In un’ottica di adozione clinica, è quindi utile verificare se modelli di machine learning tradizionale — più leggeri, rapidi da addestrare e spesso più interpretabili — possano ottenere prestazioni comparabili o superiori in specifici scenari d’uso.

❗ **Limitazione 1. Scelta metodologica ristretta.** La letteratura valuta quasi esclusivamente ANN; servono confronti sistematici con modelli TML per misurare i trade-off tra accuratezza, costo computazionale e trasparenza.

Gran parte degli studi valuta modelli personalizzati sul singolo soggetto, mentre il confronto strutturato con modelli generali è poco approfondito. Un’analisi equilibrata è cruciale per capire quando la personalizzazione possa produrre un miglioramento clinicamente significativo e quando, invece, un modello generale risulti più adatto all’impiego operativo.

❗ **Limitazione 2. Forte focus sui modelli personalizzati.** Serve un confronto sistematico con modelli generali e una valutazione della praticabilità operativa di entrambi.

Molti modelli operano come black box: ottimizzare l’accuratezza non basta in ambito clinico, dove è necessario spiegare perché una previsione è stata prodotta e se tale spiegazione è coerente con la fisiologia. Gran parte degli studi integra tecniche XAI quasi esclusivamente in problemi di classificazione; estenderle e validarle anche in un contesto regressivo è essenziale per migliorare fiducia, sicurezza d’uso e trasferibilità nella pratica clinica.

❗ **Limitazione 3. Trasparenza insufficiente.** Le predizioni vanno spiegate e validate clinicamente: occorre applicare tecniche XAI anche in regressione e verificarne la coerenza fisiologica a livello sia globale che locale.

CAPITOLO 3

Metodo di Ricerca

3.1 Obiettivo generale e Domande di Ricerca

Questa tesi mira a valutare e confrontare approcci di previsione della glicemia basati su modelli di machine learning tradizionale e su reti neurali artificiali, esplorando due modalità di addestramento — generale (dati aggregati di più pazienti) e personalizzata (modelli addestrati sul singolo paziente) — e adottando una valutazione sia statistica che clinica, con l'integrazione di tecniche di XAI a livello globale e locale. L'obiettivo è identificare le impostazioni che offrono il miglior compromesso tra accuratezza, praticabilità d'uso e trasparenza.

Dai limiti esposti nella sottosezione 2.5.1 sono state formulate le domande di ricerca che hanno guidato il processo sperimentale. La prima domanda nasce dall'eterogeneità degli esiti riportati nello stato dell'arte:

Q RQ₁. *Quali sono le performance delle reti neurali artificiali rispetto ai modelli di machine learning tradizionale nella previsione della glicemia?*

Nel nostro contesto, i modelli tradizionali possono risultare competitivi quando la dinamica glicemica è relativamente regolare, mentre le reti neurali possono cogliere non linearità e dipendenze temporali più complesse. Il confronto è condotto mediante

la stessa pipeline di machine learning e identiche procedure di validazione, combinando metriche statistiche e cliniche, in linea con l'obiettivo di stimare la migliore accuratezza predittiva in uno scenario realistico.

La seconda domanda inquadra il trade-off tra adottabilità e prestazioni:

Q RQ₂. *Qual è la differenza di performance tra un modello generale e un modello personalizzato per paziente?*

I modelli generali sono potenzialmente più immediati da distribuire, poiché non richiedono uno storico del nuovo paziente; i modelli personalizzati, invece, possono adattarsi alle caratteristiche individuali ma necessitano di dati specifici e procedure di aggiornamento. Un'analisi di tale differenza consente di comprendere quando la personalizzazione produca un guadagno clinicamente significativo e quando, invece, un modello generale possa risultare sufficiente.

In ambito clinico, la trasparenza è essenziale per fidarsi dei modelli e verificarne il comportamento in condizioni critiche; da qui la terza domanda:

Q RQ₃. *Quanto risultano spiegabili le previsioni ottenute con tecniche di XAI, sia a livello globale sia a livello locale?*

Si valuta pertanto se le spiegazioni globali restituiscano pattern coerenti e se le spiegazioni locali chiariscano, istanza per istanza, il motivo per cui una previsione è stata prodotta, includendo casi di ipo-, normo- e iperglicemia. L'uso di una libreria XAI come SHAP consente di collegare i contributi delle feature alla fisiologia, in linea con l'obiettivo generale di massimizzare non solo l'accuratezza, ma anche la comprensibilità e la verificabilità delle previsioni.

3.1.1 Panoramica del processo sperimentale




Figura 3.1: Overview dei passi principali condotti per rispondere alle RQ.

La Figura 3.1 offre una visione d’insieme del processo seguito per rispondere alle domande di ricerca. Dopo una fase di preparazione dei dati sul dataset *T1DiabetesGranada*, i dati sono partizionati in train/validation/test e sei modelli selezionati vengono addestrati utilizzando le informazioni di tutti i pazienti e valutati sul validation set. Alla valutazione segue un’ottimizzazione degli iperparametri e la scelta di due configurazioni rappresentative per le due macro-categorie a confronto (ANN e TML). La valutazione finale viene condotta sul test set e gli ultimi blocchi della pipeline sono ricondotti alle rispettive RQ: il confronto tra le famiglie di algoritmi (RQ₁), quello tra i regimi di addestramento (RQ₂) e l’analisi di spiegabilità, sia globale sia locale (RQ₃).

3.2 Esplorazione preliminare del dataset

La prima fase del lavoro ha previsto un'esplorazione accurata del dataset adottato. *T1DiabetesGranada* è un dataset longitudinale e multimodale, raccolto nell'arco di quattro anni su 736 pazienti con diabete di tipo 1 residenti nella provincia di Granada (Spagna). La struttura longitudinale e l'ampiezza del dataset, tra le più elevate in letteratura, consentono di addestrare con risultati affidabili sia modelli generali sia modelli personalizzati per soggetto, abilitando un confronto sistematico delle prestazioni.

Dopo aver richiesto e ottenuto l'accesso tramite l'apposita piattaforma (il dataset è concesso su permesso specifico), i dati sono forniti in quattro file CSV:

- **Patient_info.csv** contiene informazioni anagrafiche (sesso e anno di nascita) e di "calendario" del paziente: date di inizio e fine della partecipazione alla raccolta dati, numero totale di misurazioni registrate, numero totale di giorni con misurazioni, date della prima e dell'ultima raccolta dei parametri biochimici, conteggi di parametri e diagnosi di altre complicanze oltre il T1D. La durata di partecipazione varia ampiamente: si osservano pazienti con pochi giorni di dati e altri con oltre 1 400 giorni; il numero di misurazioni per paziente spazia da poche centinaia fino a oltre 100 000.
- **Glucose_measurements.csv** contiene le misurazioni continue della glicemia (in mg/dL) per ogni soggetto partecipante. Il sensore utilizzato è del tipo *FGM FreeStyle Libre 2*: questo registra automaticamente una misurazione ogni 15 minuti, con una tolleranza di circa 1 minuto, e l'utente può effettuare letture manuali istantanee in qualsiasi momento. L'intervallo in cui possono ricadere le osservazioni è [40, 500] mg/dL e il file è voluminoso, con oltre 22 milioni di record.
- **Biochemical_parameters.csv** contiene parametri biochimici raccolti in esami ematochimici svolti sporadicamente durante il periodo di studio.
- **Diagnostics.csv** contiene diagnosi di complicanze del diabete mellito e comorbidità presenti per ciascun paziente.

3.2.1 Distribuzione dei valori glicemici

La Figura 3.2 mostra la distribuzione delle misurazioni glicemiche contenute nel file **Glucose_measurements.csv**. Si osserva che la maggior parte dei valori si concentra tra 100 e 200 mg/dL [1]; tale concentrazione è coerente con l'obiettivo clinico di mantenere i livelli nel range normoglicemico 70–180 mg/dL, considerato sicuro.




Figura 3.2: Distribuzione delle misurazioni per il dataset *T1DiabetesGranada*.

Per caratterizzare la variabilità inter-paziente, le distribuzioni della glicemia di dieci soggetti selezionati casualmente sono state rappresentate tramite box plot (Figura 3.3). Le differenze tra i soggetti emergono non solo nel valore della mediana, ma anche nella dimensione dei range interquartili (IQR) e nel numero di outlier. In alcuni profili i box risultano compatti, in altri sono più estesi e presentano code pronunciate, indicando una maggiore frequenza di episodi estremi. Tali differenze sono compatibili con eterogeneità nello stile di vita e nella terapia (dieta, attività fisica, quantità di insulina iniettata) e suggeriscono che il comportamento glicemico sia fortemente dipendente dal singolo soggetto.

Analizzando i box plot dell'intero campione e quelli dei sottogruppi per sesso ed età (Figura 3.6) non emergono differenze sistematiche rilevanti. Le mediane sono simili, gli IQR ampiamente sovrapposti e la variabilità intra-gruppo supera quella tra gruppi. In sintesi, le caratteristiche demografiche non mostrano un effetto dominante




Figura 3.3: Box plot per 10 pazienti scelti casualmente.

sulla distribuzione dei livelli glicemici; ciò orienta il metodo di ricerca verso la modellazione delle sole misurazioni CGM senza introdurre ulteriori covariate.

3.2.2 Dipendenza temporale

Nei problemi di previsione su serie temporali, i valori futuri vengono inferiti a partire da quelli passati, presupponendo una dipendenza seriale lungo l'asse temporale. In questo contesto, si indicano come *lag* le osservazioni precedenti all'istante di predizione: il valore a un passo indietro è *lag 1*, a due passi *lag 2*, e così via. La misura più utilizzata per analizzare la dipendenza seriale è l'*autocorrelazione*; la relativa funzione (ACF) mostra, al variare del lag, la correlazione tra la serie e la sua versione ritardata.

Nel selezionare i lag da usare come feature in un problema supervisionato, non è utile includere indiscriminatamente tutti quelli con autocorrelazione elevata: ad esempio, l'autocorrelazione al lag 2 può riflettere informazione già contenuta nel lag 1, ossia una correlazione "trascinata" dallo step immediatamente precedente. Se il lag 2 non aggiunge nuova informazione, non vi è motivo di includerlo quando il lag 1 è già presente. Qui interviene l'*autocorrelazione parziale*: la rispettiva funzione (PACF) fornisce la correlazione di un lag depurata dell'effetto di tutti i lag precedenti, quantificando quanta "nuova" informazione apporta ciascun lag.

Focalizzando il problema sulla previsione a breve termine e, per ragioni di leggibilità, le ACF e le PACF non sono state tracciate sull'intero intervallo di possibili lag, ma fino a una soglia di 50; i risultati della funzione ACF sono visibili in Figura 3.4. Anche qui emergono differenze tra pazienti: per alcuni soggetti l'autocorrelazione decresce rapidamente, segnalando una debole dipendenza oltre i primi lag; per altri l'autocorrelazione persiste su più lag, indicando dipendenze più "lente" e, conseguentemente, una migliore prevedibilità per orizzonti di previsione più lunghi.




Figura 3.4: Funzione di autocorrelazione (ACF) per i pazienti *LIB193555* e *LIB193645*.

Le funzioni PACF sono riportate in Figura 3.5. Per molti pazienti, il numero di lag con autocorrelazione parziale significativa — ossia al di fuori della banda azzurra di confidenza che indica assenza di correlazione — è compreso tra 3 e 10. Ciò è in linea con l'intervallo operativo 2–14 utilizzato nel processo di tuning della *history length* eseguito da Rodriguez Leon e descritto nella Sezione 2.5.

È importante ricordare che autocorrelazione e autocorrelazione parziale misurano dipendenze lineari. Ciò non esclude che modelli non lineari possano catturare pattern non evidenti nei grafici ACF e PACF. Tuttavia, il fatto che diversi lag risultino al di fuori dell'intervallo di confidenza associato all'ipotesi di assenza di correlazione consente di escludere che la serie temporale studiata sia un *rumore bianco*, ovvero una sequenza di osservazioni indipendenti e imprevedibili. Ne consegue che la scelta di predire la glicemia utilizzando le serie temporali del *T1DiabetesGranada* è metodologicamente fondata.




Figura 3.5: Funzione di autocorrelazione parziale (PACF) per i pazienti *LIB193457*, *LIB193486*, *LIB193482* e *LIB193446*.

3.3 Preparazione dei dati

Dopo la fase di esplorazione, è stata avviata l'operazione di preprocessing dei dati e la costruzione degli input per i modelli sotto forma di finestre temporali.

I file originali erano già stati sottoposti a un'operazione di rimozione dei duplicati in fase di costruzione del dataset [2]; verificato ciò, sono stati applicati i passaggi descritti nelle sottosezioni seguenti.

3.3.1 Rimozione degli outlier

I sensori impiegati nella raccolta hanno un range di lettura compreso tra 40 e 500 mg/dL: qualsiasi misurazione al di fuori di questo intervallo viene registrata con uno dei due valori limite. In questa tesi si è deciso di escludere le osservazioni al di




Figura 3.6: Distribuzione delle misurazioni glicemiche: generale; per sesso; per età. Fonte: [2]

fuori del range $[40, 400]$ mg/dL, trattandole come outlier. La scelta è motivata da due ragioni, metodologiche e cliniche:

- **Allineamento con la valutazione clinica.** Il modello standard della Clarke Error Grid (CEG), descritto nella Sottosezione 3.4.4, adotta assi cartesiani con range $[0, 400]$ mg/dL. Limitare il dominio evita la presenza di numerosi punti fuori dalla griglia e garantisce una valutazione clinica facilmente riproducibile.
- **Rilevanza clinica.** Valori superiori a 400 mg/dL ricadono ben oltre l’inizio della fascia TAR-L2 (che parte da 250 mg/dL). Osservazioni di questo tipo indicano un’iperglicemia severa che richiederebbe prioritariamente un intervento clinico più che una previsione algoritmica a breve termine. Nella pratica, letture superiori a 300 mg/dL sono considerate critiche e motivo di valutazione urgente [32].

Su un totale di 22 671 708 record, ne sono stati rimossi 165 525 (circa lo 0.7% del totale).

3.3.2 Resampling

Come evidenziato nella Sezione 3.2, gli intervalli tra le misurazioni glicemiche (il Δt) non sono costanti. Oltre alle acquisizioni automatiche ogni 15 minuti, le scansioni manuali del paziente generano misurazioni aggiuntive con Δt inferiore a 15 minuti. Si osservano inoltre registrazioni automatiche con Δt pari a 14 o 16 minuti (e oltre), dovute alla tolleranza di 1 minuto del sensore. Infine, sono presenti intervalli molto ampi, causati da guasti, batteria scarica o pause volontarie del paziente nella partecipazione allo studio. L’obiettivo è ottenere una serie temporale regolare con frequenza fissa di 15 minuti, senza campioni intermedi.

Una possibile strategia consiste nel rimuovere i campioni in eccesso all’interno di finestre di 15 minuti (*downsampling*) e colmare i Δt più ampi inserendo manualmente nuove misurazioni con cadenza di 15 minuti (*upsampling*).

È stato applicato il downsampling con cadenza fissa di 15 minuti secondo due regole:

1. le osservazioni derivanti da letture manuali che cadono tra due letture automatiche vengono rimosse;
2. le osservazioni automatiche con lievi scostamenti temporali vengono riallineate per ottenere un Δt di 15 minuti.

La Figura 3.7 illustra due casi rappresentativi di applicazione delle regole:

- **Caso 1:** sono presenti quattro osservazioni e la terza è una misurazione manuale compresa tra due automatiche. Viene rimossa, mentre le altre tre sono mantenute.
- **Caso 2:** sono presenti tre osservazioni automatiche, con la seconda registrata in ritardo e la terza in anticipo. Queste due vengono riallineate, posizionandole nello slot temporale di 15 minuti più vicino.




Figura 3.7: Casi rappresentativi su cui è stato applicato il downsampling.

Per i gap più ampi, un upsampling tramite interpolazione potrebbe essere una soluzione, ma rischierebbe di introdurre traiettorie irrealistiche in un contesto non

lineare come quello della glicemia e potrebbe favorire l'*overfitting* dei modelli. Si è quindi deciso di non applicarlo: i valori mancanti sono stati trattati come sconosciuti e, in fase di training, sono state escluse tutte le finestre temporali che li contengono.

3.3.3 Campionamento minimo per l'addestramento

Coerentemente con [1], sono stati mantenuti solo i soggetti con almeno un mese di misurazioni. Tale soglia garantisce un volume di dati adeguato all'addestramento di reti neurali ricorrenti, riducendo il rischio di *overfitting* e migliorando la capacità di generalizzazione. La soglia è stata calcolata sul numero di record effettivi: un giorno completo equivale a 96 campioni (uno ogni 15 minuti), quindi 30 giorni corrispondono a 2880 campioni. Applicando il criterio, sono stati esclusi 47 soggetti, lasciandone 689 per il prosieguo della pipeline.

3.3.4 Preparazione delle finestre scorrevoli

Per trasformare il problema in uno di apprendimento supervisionato, i dati devono essere riorganizzati in istanze di input con i corrispondenti valori target. Nei problemi di forecasting su serie temporali, gli input vengono espressi come *finestre temporali*. Queste comprendono un numero di osservazioni definito *history length* (HL), mentre i target associati a ogni finestra sono i campioni del futuro posti a una distanza definita *prediction horizon* (PH).

È stata adottata una HL di 8 campioni (2 ore) e un PH di 2 campioni (30 minuti nel futuro). Tale scelta privilegia l'orizzonte più breve tra i due (30 e 60 minuti) utilizzati nelle *Blood Glucose Level Prediction Challenges* [27, 28]. Sono state quindi costruite finestre scorrevoli sui dati con passo di 1 campione, scartando le finestre contenenti almeno una misurazione sconosciuta. La dimensione del dataset, infatti, consente comunque la costruzione di un ampio set di istanze di input per l'addestramento. La Figura 3.8 mostra un esempio nel processo di costruzione delle finestre con $HL = 4$, $PH = 2$ e passo unitario.




Figura 3.8: Esempio di costruzione delle finestre scorrevoli per una HL di 4 campioni (1 ora) e un PH di 2 campioni (0,5 ore), con passo unitario.

3.3.5 Feature scaling

Per favorire la convergenza delle reti neurali, i dati sono stati normalizzati nell'intervallo $[-1, 1]$, utilizzando una trasformazione analoga alla *Min-Max normalization* replicata in [33]. La formula impiegata è:

$$x_{norm} = \left[2 * \frac{x - \min x}{\max x - \min x} - 1 \right] \quad (3.3.1)$$

dove $\min x = 40$ e $\max x = 400$, in coerenza con il range analitico adottato. Al termine dell'inferenza è stata applicata la trasformazione inversa per riportare le previsioni alla scala originale, ai fini della valutazione clinica e della redazione delle tabelle di reportistica.

3.4 Valutazione preliminare dei modelli

In questa sezione è stata condotta una prima valutazione comparativa di modelli appartenenti a due famiglie — machine learning tradizionale e reti neurali artificiali — utilizzando, come parametri di configurazione sia valori predefiniti sia valori replicati da uno studio preso come riferimento. L'obiettivo è individuare i candidati più promettenti da sottoporre a un'ottimizzazione degli iperparametri nelle sezioni successive. Inoltre, è stato valutato un modello "tradizionale" su un sottoinsieme arricchito con covariate demografiche e biochimiche, per stimare l'effettivo beneficio della loro inclusione.

3.4.1 Modelli considerati

Traditional Machine Learning (TML)

I modelli di machine learning tradizionale sono robusti, veloci da addestrare e spesso sufficienti a ottenere buoni risultati di base; uno degli obiettivi della tesi è confrontare la qualità delle loro prestazioni con quella, più complessa, delle reti neurali. Sono stati quindi valutati tre modelli: *Random Forest* (RF), *LightGBM* (LGB) e *XGBoost* (XGB). Di seguito se ne riassumono il funzionamento e le principali caratteristiche.

- **Random Forest.** Aggregando le previsioni di un insieme di modelli (classificatori o regressori) si ottengono spesso stime migliori del singolo miglior modello. Un insieme di modelli è detto *ensemble* e un algoritmo di apprendimento di questo tipo è un *metodo di ensemble*. Un esempio è l'addestramento di più alberi decisionali, ciascuno su un sottoinsieme casuale del training set e con un sottoinsieme casuale di feature; le previsioni dei singoli alberi vengono aggregate e, nei problemi di classificazione, la classe più votata costituisce la previsione finale. Un ensemble di alberi di questo tipo è la Random Forest che, nonostante la semplicità, è tra gli algoritmi di machine learning più efficaci.
- **Algoritmi di gradient boosting.** Con *boosting* si indica qualsiasi metodo di ensemble che combina più modelli deboli (*weak learners*) in un modello forte

(*strong learner*). L'idea è addestrare modelli in sequenza, così che ciascuno corregga gli errori del precedente. Un approccio molto diffuso è il *gradient boosting*. In ambiente Python sono disponibili implementazioni ottimizzate, tra cui XGBoost e LightGBM, ciascuna con specifiche peculiarità; in questo studio sono considerate entrambe.

Per il confronto preliminare, ciascun modello è stato addestrato con gli iperparametri predefiniti dalle relative librerie in cui è implementato. In particolare, sono state utilizzate SCIKIT-LEARN — con cui è stata costruita l'intera pipeline di preprocessing descritta in 3.3 —, XGBOOST e LIGHTGBM. Si noti che gli algoritmi di ensemble considerati non richiedono la normalizzazione dei dati; tuttavia, tale operazione non degrada la qualità della previsione ed è stata pertanto mantenuta per coerenza e conformità.

Artificial Neural Networks (ANN)

Le reti neurali artificiali sono modelli di apprendimento automatico ispirati al funzionamento delle reti di neuroni del cervello umano. Sono il cuore del *deep learning*: versatili, potenti e scalabili, risultano ideali per compiti di grande complessità e dimensione, come la classificazione di miliardi di immagini (ad es. Google Images), il riconoscimento vocale (ad es. Siri), i sistemi di raccomandazione su larga scala (ad es. YouTube) o lo sviluppo di agenti capaci di apprendere regole e strategie di giochi a turni fino a battere campioni mondiali (ad es. AlphaGo).

Nel presente studio sono state considerate tre tipologie di modelli: *MLP*, *LSTM* e *GRU*, descritte di seguito.

- **MLP (Multi-Layer Perceptron).** È una rete neurale *feed-forward* composta da più strati di neuroni artificiali (gli *hidden layers*). I dati in ingresso fluiscono dallo strato di input attraverso uno o più strati nascosti: in ciascuno, ogni neurone calcola una combinazione lineare degli input mediante pesi (*weights*) e *bias*, quindi applica una *funzione di attivazione*. Il processo si ripete strato dopo strato, e l'output dell'ultimo strato nascosto viene passato allo strato di output, che produce la previsione. Per migliorare l'accuratezza, gli MLP applicano

il processo di *backpropagation* per aggiornare pesi e bias di ciascun neurone, apprendendo dagli errori commessi nelle previsioni precedenti.

- **RNN (Recurrent Neural Networks).** Le RNN sono progettate per dati sequenziali (serie temporali, testo, audio). A differenza delle reti feed-forward, una cella ricorrente mantiene uno stato interno che si aggiorna a ogni passo temporale. Al tempo t un'unità ricorrente riceve l'input x_t e lo stato precedente h_{t-1} , elabora le informazioni e produce il nuovo stato h_t e l'output relativo all'istante t . Questa "ricorrenza" consente di modellare dipendenze temporali e, una volta appresi i pattern storici nello stato h , di prevedere valori futuri con buona accuratezza, purché le regolarità osservate si mantengano nel tempo.

Attraversando molti passi temporali, tuttavia, parte dell'informazione sulle dipendenze di lungo periodo tende a perdersi; inoltre, durante la *backpropagation* possono manifestarsi i problemi di *vanishing* o *exploding gradients*. Per mitigare tali effetti sono state introdotte unità ricorrenti con memoria di lungo termine, oggi molto più diffuse delle unità semplici:

- **LSTM (Long Short-Term Memory).** Proposta da Hochreiter e Schmidhuber (1997), introduce uno stato di lungo termine e tre funzioni di *gating* che la rete impara a controllare: l'*input gate* decide quali informazioni memorizzare, il *forget gate* quali dimenticare e l'*output gate* quanto la memoria debba influenzare l'output finale. Trattata come black box, un'unità LSTM si usa come una normale unità ricorrente, ma tende a convergere più rapidamente e a catturare dipendenze più lunghe nel tempo, migliorando le prestazioni su molte sequenze reali.
- **GRU (Gated Recurrent Unit).** Introdotta da Cho et al. (2014), semplifica l'unità LSTM utilizzando solo due gate (di *reset* e di *update*). Un modello con celle GRU ha meno parametri da gestire e può essere più veloce da addestrare, mantenendo prestazioni spesso comparabili a quelle delle LSTM.

3.4.2 Architetture ANN scelte

Le reti neurali artificiali (ANN) descritte nella Sottosezione 3.4.1 ricevono in input sequenze di misurazioni CGM e forniscono un singolo output, corrispondente alla previsione a 30 minuti nel futuro. Le architetture — definite dal numero di hidden layers e di unità per strato, dalle funzioni di attivazione e dalla percentuale di *dropout* applicata agli output — sono state replicate dal lavoro di Chu et al. [33] e sono riportate in Figura 3.9.




Figura 3.9: Architetture dei modelli ANN considerati.

Il modello MLP comprende due hidden layer completamente connessi, ciascuno con 256 neuroni. Utilizza come funzione di attivazione la tangente iperbolica (Tanh) e applica un dropout del 20% al termine di ogni strato. In totale, il modello conta 68 353 parametri.

Il modello LSTM è composto da due hidden layer da 75 neuroni, con dropout del 20%, seguiti da uno strato *dense* che trasforma l'uscita (di dimensione 75) degli strati ricorrenti in un singolo valore. La rete ha complessivamente 68 476 parametri.

Il modello GRU è implementato in modo analogo all'LSTM, ma con hidden layer da 86 neuroni, per un totale di 67 941 parametri.

Tutte le reti neurali sono state implementate e addestrate utilizzando la libreria TENSORFLOW. Anche i parametri di addestramento sono stati replicati dallo studio di riferimento; sono riportati in dettaglio in Tabella 3.1. La funzione di costo è la *Huber Loss* e l'ottimizzatore è *Adam* con *learning rate* iniziale pari a 0.01. I modelli sono stati addestrati per un massimo di 100 epoche con *batch size* di 4 096. Sono state inoltre adottate tecniche per accelerare l'addestramento e ridurre il rischio di overfitting: *learning-rate scheduling* ed *early stopping*. Lo scheduler riduce il learning rate di un fattore 0.1 quando il modello, valutato sul validation set, non mostra miglioramenti per tre epoche consecutive (*Learning Rate Scheduler Patience*), con un limite minimo raggiungibile di 10^{-6} . In parallelo, l'addestramento si interrompe se il MAE sul validation set non migliora per cinque epoche consecutive (*Early Stopping Patience*).

Tabella 3.1: Riepilogo dei parametri di addestramento delle ANN.

Parametro	Valore
Criterion	Huber Loss
Optimizer	Adam
Epoch	100
Batch Size	4096
Initial Learning Rate	0.01
Learning Rate Reduction Factor	0.1
Learning Rate Scheduler Patience	3
Minimum Learning Rate	10^{-6}
Early Stopping Patience	5

3.4.3 Metriche di valutazione statistiche

Di seguito sono riportate le metriche statistiche utilizzate per la valutazione delle prestazioni:

- **Mean Absolute Error (MAE).** Calcola l'errore medio, in valore assoluto, tra i valori previsti $\hat{y}_i$ e quelli osservati y_i :

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i|. \quad (3.4.1)$$

- **Mean Absolute Percentage Error (MAPE).** Esprime il MAE in percentuale, favorendo un'interpretazione più immediata:

$$\text{MAPE} = \frac{1}{N} \sum_{i=1}^N \frac{|\hat{y}_i - y_i|}{y_i}. \quad (3.4.2)$$

- **Root Mean Squared Error (RMSE).** Calcola la radice quadrata dell'errore quadratico medio tra $\hat{y}_i$ e y_i :

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2}. \quad (3.4.3)$$

3.4.4 Valutazione clinica: la Clarke Error Grid

La *Clarke Error Grid* (CEG) è una procedura di valutazione clinica ampiamente adottata per misurare quanto siano sicure le previsioni glicemiche dei modelli di apprendimento, andando oltre le sole metriche numeriche come MAE e RMSE. La CEG permette di valutare non solo "quanto" sbaglia un modello, ma anche "quanto può far male" l'errore di predizione.

Operativamente, la CEG può essere vista come un grafico di dispersione: ogni punto ha come coordinata orizzontale la glicemia realmente registrata e come coordinata verticale la glicemia prevista (Figura 3.10). La diagonale grigia individua i punti in cui la previsione coincide esattamente con il valore di riferimento, ossia le predizioni perfettamente accurate.

Il piano cartesiano è suddiviso in cinque regioni (A–E), definite in base all'impatto clinico dell'errore:

- **Regione A:** predizioni clinicamente accurate. I valori previsti differiscono dai valori di riferimento di non più del 20%.
- **Regione B:** predizioni clinicamente accettabili. La differenza supera il 20%, ma un trattamento basato su tali valori non risulterebbe inappropriato.
- **Regione C:** predizioni scorrette. I valori previsti suggeriscono la necessità di un trattamento, mentre i valori reali indicano che il trattamento non è necessario.
- **Regione D:** errori pericolosi. I valori previsti sono così imprecisi da non rilevare ipoglicemie o iperglicemie potenzialmente pericolose.

- **Regione E:** errori critici. Il modello non solo non rileva condizioni pericolose (come nella Regione D), ma confonde anche l'una con l'altra: riporta iperglicemia quando il campione è in realtà ipoglicemico e viceversa.




Figura 3.10: Visualizzazione della Clarke Error Grid vuota.

3.4.5 Addestramento e valutazione

Prima di addestrare i modelli oggetto di confronto, i dati sono stati suddivisi in tre sottoinsiemi, come illustrato in Figura 3.11. Il training set comprende 483 pazienti (circa il 70% del totale), il validation set 68 pazienti (circa il 10%) e il test set i restanti 138 pazienti (circa il 20%). La suddivisione è stata eseguita in modo stratificato rispetto alle condizioni glicemiche, così da preservare distribuzioni simili nei tre sottoinsiemi. Si osservi inoltre che la separazione è stata effettuata in modo inter-paziente: ciascun soggetto compare in uno solo dei sottoinsiemi, prevenendo potenziali fenomeni di *leakage* dei dati.

In questa fase i modelli sono stati valutati sul validation set: mantenere un insieme di validazione indipendente consente di ottimizzare successivamente gli iperparametri senza utilizzare il test set finale. Questa scelta è stata preferita a una *k-fold cross validation* per ridurre il costo computazionale, dato l'elevato volume di dati




Figura 3.11: Distribuzione per condizione clinica dei dati nei set.

disponibili. Al contempo, la quantità di dati a disposizione consente di ottenere stime affidabili anche senza ripetere l'addestramento su k partizioni del training set.

Sono stati quindi addestrati i modelli e valutate le predizioni per ciascun paziente del validation set; successivamente sono state calcolate le medie e le deviazioni standard. I risultati sono riportati in Tabella 3.2.

Tabella 3.2: Prestazioni cumulative dei modelli valutati sul validation set.

Modello	MAE	MAPE (%)	RMSE
RF	14.82 (2.40)	10.50 (1.96)	20.35 (3.34)
LGB	14.29 (2.21)	10.04 (1.75)	19.66 (3.07)
XGB	14.05 (2.13)	9.85 (1.71)	19.37 (2.96)
MLP	13.65 (2.08)	9.49 (1.63)	18.98 (2.89)
LSTM	13.55 (2.05)	9.44 (1.61)	18.79 (2.85)
GRU	13.54 (2.04)	9.47 (1.63)	18.77 (2.84)

In media, le reti neurali superano i modelli tradizionali su tutte le metriche: il MAE varia in $[13.54, 13.65]$ per le reti neurali contro $[14.05, 14.82]$ per i modelli tradizionali; analogamente, l'RMSE scende a $[18.77, 18.98]$ per le reti rispetto a $[19.37, 20.35]$, con differenze coerenti anche per il MAPE. Tra i tradizionali, gli algoritmi di boosting risultano i più competitivi, con XGB leggermente migliore. Tra le reti, le ricorrenti sono stabilmente in testa: GRU ottiene un RMSE pari a 18.77 e un MAE pari a 13.54, più bassi di LSTM, che segna però il MAPE minimo (9.44). Anche le deviazioni stan-

dard risultano inferiori rispetto a quelle dei metodi tradizionali, segno di prestazioni più stabili sulla popolazione.

Sulla base di questa prima valutazione, si è quindi deciso di procedere con un tuning approfondito dei modelli di boosting e delle reti ricorrenti, per individuare due modelli rappresentativi delle rispettive categorie.

3.5 Addestramento con più feature

Nell'esperimento descritto in questa sezione sono stati utilizzati i dati anagrafici e biochimici provenienti dai file **Patient_info.csv** e **Biochemical_parameters.csv**, illustrati nella Sezione 3.2. Per valutare se variabili aggiuntive possano migliorare la previsione glicemica, è stato costruito un sottoinsieme del dataset con le variabili anagrafiche "sesso" ed "età" e alcune variabili biochimiche, integrate alle serie CGM.

I parametri biochimici non sono sempre stati raccolti integralmente durante le singole visite. La Figura 3.12 mostra la distribuzione del numero di parametri biochimici presenti nel dataset.




Figura 3.12: Distribuzione del numero di record dei parametri biochimici. Fonte: [2]

Sulla base di tale distribuzione è stato scelto un sottoinsieme di parametri da integrare nell'input:

- **HbA1c**, rappresentativa della media glicemica dei pazienti nei precedenti 2–3 mesi;
- **TSH**, utile per valutare la funzione tiroidea;
- **Creatinina**, indicatore della funzione renale;
- **Trigliceridi e HDL**.

Le variabili anagrafiche e biochimiche selezionate sono state trattate come covariate e aggiunte come feature alle finestre CGM precedentemente costruite. "Sesso" ed "età" sono state replicate per tutte le finestre del paziente corrispondente. Per le biochimiche, invece, è stata applicata una strategia di *backward-filling*: ogni misurazione biochimica viene replicata per 30 giorni con frequenza di 15 minuti e concatenata alle finestre con il lag 0 corrispondente. Le finestre prive del valore di almeno una feature sono state rimosse.

Il set di addestramento così costruito è composto da 2 279 320 finestre di 10 feature ciascuna, suddivise in train, validation e test set con le proporzioni 70/10/20. Sul sottoinsieme con feature aggiunte è stato addestrato un XGB con iperparametri di default e valutato sul validation set. I risultati sono riportati in Tabella 3.3.

Tabella 3.3: Prestazioni cumulative del modello XGB standard sul sottoinsieme costruito.

Modello	MAE	MAPE (%)	RMSE
XGB	14.05 (2.58)	9.94 (2.05)	19.31 (3.68)

Le prestazioni cumulative non mostrano benefici rispetto all'XGB addestrato sulle sole feature glicemiche: il MAE resta pari a 14.05, con una deviazione standard che aumenta a 2.58; un andamento analogo si osserva per MAPE e RMSE. Per interpretare meglio il contributo delle feature sono state calcolate le *feature importance* del modello, che quantificano la riduzione della loss attribuibile a ciascuna feature. In Figura 3.13 è riportata la ripartizione percentuale (normalizzata per una miglior visualizzazione) per categoria: il grafico conferma la predominanza delle lag glicemiche (98.5%), con contributi trascurabili per le covariate biochimiche (1.3%) e anagrafiche (0.2%).




Figura 3.13: Importanza delle categorie di feature per il modello XGBoost standard.

È rilevante notare che l'introduzione di feature supplementari abbia ridotto drasticamente il numero di finestre utilizzabili per l'addestramento: 2 279 320 contro le 19 864 996 ottenibili con i soli valori CGM. In sintesi, l'aggiunta non sembra apportare benefici in termini di accuratezza, comporta un'elevata perdita di copertura dei dati e, in uno scenario reale con un dispositivo che registri e preveda automaticamente i valori glicemici futuri, risulterebbe poco pratica richiedendo l'inserimento manuale di nuovi valori ogni mese.

3.6 Ottimizzazione dei modelli

3.6.1 Modelli di gradient boosting

Considerate le prestazioni superiori dei metodi di gradient boosting rispetto all'algoritmo Random Forest nella valutazione della Sottosezione 3.4.5, sono state selezionate entrambe le implementazioni — XGBoost e LightGBM — per un processo di ottimizzazione degli iperparametri.

Per esplorare in modo efficace lo spazio delle possibili configurazioni è stata utilizzata la libreria OPTUNA, *open-source*, che consente un'ottimizzazione automatica basata su *ricerca bayesiana*: a differenza delle ricerche casuali o a griglia, seleziona i valori degli iperparametri in funzione dei risultati dei tentativi precedenti, prevedendo le combinazioni più promettenti. Sono state quindi eseguite 40 iterazioni per ciascuno dei due modelli, con l'obiettivo di minimizzare la media dei MAE calcolati per paziente sul validation set. I range degli iperparametri chiave sono riportati in Tabella 3.4.

Tabella 3.4: Spazi di ricerca per il tuning di LightGBM e XGBoost.

LightGBM	XGBoost
num_leaves $\in [10, 300]$	max_depth $\in [3, 10]$
max_depth $\in [3, 12]$	min_child_weight* $\in [0.1, 10]$
min_data_in_leaf $\in [5, 50]$	subsample $\in [0.6, 1.0]$
min_child_weight* $\in [10^{-3}, 10]$	colsample_bytree $\in [0.6, 1.0]$
subsample $\in [0.6, 1.0]$	gamma* $\in [10^{-8}, 1.0]$
colsample_bytree $\in [0.6, 1.0]$	learning_rate* $\in [0.01, 0.3]$
learning_rate* $\in [0.01, 0.3]$	reg_alpha* $\in [10^{-8}, 10]$
reg_alpha* $\in [10^{-8}, 10]$	reg_lambda* $\in [10^{-8}, 10]$
reg_lambda* $\in [10^{-8}, 10]$	n_estimators $\in [100, 1000]$

* Ricerca su scala logaritmica.

L'esito del tuning ha prodotto un miglioramento sistematico rispetto alle versioni con valori di default: sia LGB sia XGB hanno registrato prestazioni migliori sul validation set per tutte le metriche considerate, pur rimanendo leggermente dietro alle reti neurali. I risultati sono riportati in Tabella 3.5. Poiché le prestazioni di XGB sono risultate lievemente superiori a quelle di LGB, è stato scelto come modello rappresentativo della classe dei modelli di ML tradizionale.

Tabella 3.5: Prestazioni cumulative dei modelli ottimizzati.

Modello	MAE	MAPE (%)	RMSE
LGB	13.79 (2.08)	9.65 (1.66)	19.06 (2.89)
XGB	13.76 (2.09)	9.63 (1.67)	19.03 (2.91)

3.6.2 Reti neurali ricorrenti

È stato eseguito un processo di ottimizzazione anche per le reti neurali, concentrato sulle due reti ricorrenti — LSTM e GRU — che avevano mostrato prestazioni migliori della rete feed-forward MLP. Si è adottato un approccio incrementale:

1. sono stati mantenuti tutti i parametri di configurazione della prima fase di addestramento, riportati in Tabella 3.1;

2. in una prima fase è stato scelto un modello LSTM con architettura standard e si è fatto variare il numero di neuroni negli hidden layer ricorrenti: la valutazione migliore è stata ottenuta con 128 unità;
3. fissato il numero di unità a 128, è stata effettuata una *grid search* su tre categorie di parametri: tipo di unità ricorrenti, numero di layer e percentuale di dropout. I range esplorati sono riportati in Tabella 3.6.

Tabella 3.6: Range di parametri esplorati per i modelli ricorrenti (LSTM/GRU).

Rete ricorrente
hidden units $\in \{50, 64, 75, 86, 100, \mathbf{128}\}$
cella ricorrente* $\in \{LSTM, GRU\}$
layers* $\in \{1, 2\}$
dropout* $\in \{0, 0.1, 0.2, 0.4\}$

* Parametri modificati solo dopo aver scelto il numero ottimale di hidden units.

Le migliori configurazioni ottenute sono risultate tutte molto simili in termini di prestazioni e non hanno mostrato guadagni rilevanti rispetto alle configurazioni standard adottate in 3.4.5: il miglioramento è stato di soli 0.01 punti di MAE. Alla luce di questi risultati, per la categoria delle reti neurali è stata scelta come modello rappresentativo la rete ricorrente con unità GRU e architettura illustrata in Figura 3.9. L'utilizzo di 86 unità, invece di 128, offre un buon compromesso tra accuratezza e costo computazionale nell'addestramento comparativo finale.

CAPITOLO 4

Analisi dei Risultati

In questo capitolo vengono presentati i risultati sperimentali ottenuti dalla valutazione sul test set dei modelli rappresentativi scelti nel Capitolo 3, confrontandone prestazioni e interpretabilità. Saranno quindi fornite le risposte alle domande di ricerca che hanno guidato lo studio.

4.1 Prestazioni delle ANN rispetto agli algoritmi TML

Sono state inizialmente valutate le prestazioni dei modelli generali. Un modello generale è addestrato su un'ampia quantità di dati glicemici provenienti da molti pazienti e poi impiegato per effettuare previsioni su soggetti mai visti in addestramento. Poiché le dinamiche dei nuovi pazienti possono aderire solo in parte ai pattern osservati nei dati di training, la strategia per addestrare un buon modello generale consiste nel massimizzare la copertura dei comportamenti glicemici riscontrabili, includendo il maggior numero possibile di osservazioni in fase di addestramento.

L'attività di addestramento replica esattamente la pipeline descritta nel Capitolo 3, con la differenza che i due modelli rappresentativi scelti sono stati questa volta valutati sul test set. La Tabella 4.1 riporta le performance aggregate sui pazienti in termini di metriche statistiche, mentre la Tabella 4.2 fornisce maggiori dettagli mo-

strandendo i risultati suddivisi per condizione glicemica. Le due tabelle indicano che la rete ricorrente GRU ottiene valori lievemente migliori del modello tradizionale XGB, con una differenza in termini di MAE di 0.19, ovvero circa l'1% di miglioramento.

Tabella 4.1: Prestazioni cumulative dei due modelli rappresentativi.

Modello	MAE	MAPE (%)	RMSE
GRU	13.24 (2.07)	9.21 (1.48)	18.38 (2.86)
XGB	13.43 (2.12)	9.35 (1.49)	18.62 (2.94)

Tabella 4.2: Prestazioni per condizione glicemica.

Condizione	Metrica	GRU	XGB
Normoglicemia	MAE	11.97 (1.85)	12.11 (1.87)
	MAPE (%)	9.78 (1.57)	9.90 (1.58)
	RMSE	16.74 (2.56)	16.90 (2.60)
Iperglicemia	MAE	15.69 (2.40)	15.95 (2.47)
	MAPE (%)	6.89 (1.03)	7.00 (1.04)
	RMSE	21.29 (3.15)	21.62 (3.23)
Ipoglicemia	MAE	13.67 (3.65)	13.90 (3.49)
	MAPE (%)	22.88 (6.18)	23.28 (5.95)
	RMSE	17.26 (4.51)	17.43 (4.35)

Per la valutazione clinica, la Tabella 4.3 riporta la distribuzione percentuale dei punti nelle regioni della Clarke Error Grid, mentre la Figura 4.1 ne offre la rappresentazione grafica. Anche in questo caso la le differenze tra i modelli tra le stesse regioni appare visibile seppur limitata.

I risultati non evidenziano un divario ampio, ma mostrano un vantaggio piccolo e consistente della rete neurale ricorrente sul modello tradizionale. Considerato quindi il minor costo computazionale di XGB, la scelta di un modello piuttosto che un altro in un applicazione reale dipende dal *trade-off* tra un lieve miglioramento in accuratezza offerto da GRU e efficienza e semplicità di utilizzo di XGB.

È quindi possibile fornire una risposta alla prima Domanda di Ricerca.

Regione	GRU	XGB
A	89.00%	88.72%
B	9.28%	9.49%
C	0.01%	0.01%
D	1.72%	1.78%
E	0.00%	0.00%
Clinicamente accettabili (A+B)	98.27%	98.21%
Clinicamente pericolose (D+E)	1.72%	1.78%

Tabella 4.3: Distribuzione delle inferenze nelle regioni della Clarke Error Grid.




Figura 4.1: Visualizzazione della Clarke Error Grid per i modelli generali.

🔗 **Answer to RQ₁.** Nel setting dei modelli generali sul dataset *T1DiabetesGranada*, la rete neurale ricorrente GRU mostra un vantaggio limitato ma costante rispetto ad un modello di machine learning XGB ottimizzato. In sintesi, le ANN ottengono migliori prestazioni rispetto ai modelli TML, sebbene contenute.

4.2 Prestazioni dei modelli generali rispetto ai personalizzati

La letteratura riporta numerosi studi che impiegano modelli personalizzati addestrati sui dati di singoli pazienti. È plausibile che un modello generale, addestrato su un insieme che mescola serie temporali con dipendenze diverse tra loro (come discusso in 3.2.2), non riesca ad apprendere pattern davvero condivisi da tutti i pazienti coinvolti.

Valutando le predizioni del modello generale GRU per ciascun paziente del test set, sono stati identificati i soggetti con la migliore e la peggiore valutazione; i risultati sono riportati in Tabella 4.4. La marcata differenza tra i due esiti conferma ulteriormente l'elevata eterogeneità inter-paziente: esistono profili con dinamiche glicemiche poco rappresentate nel training set, per i quali il modello generale non fornisce buone previsioni.

Tabella 4.4: Migliore e peggiore valutazione per il modello GRU sul test set.

Paziente	MAE	MAPE (%)	RMSE
<i>LIB193939</i>	8.44	9.37	11.54
<i>LIB194117</i>	18.28	13.12	25.36

Per rispondere alla seconda Domanda di Ricerca è stato quindi condotto un confronto tra modelli personalizzati e modelli generali. Un modello personalizzato è addestrato specificamente sulla serie CGM di un singolo paziente e non è pensato per generalizzare ad altri soggetti. Addestrare un modello per ogni individuo sarebbe troppo oneroso per il presente studio; ci si è dunque concentrati sui due casi estremi presentati in precedenza: il paziente con il miglior esito e quello con il peggiore. Per entrambi, le serie sono state suddivise in due sottoinsiemi, come mostrato in Figura 4.2: a partire dalla prima osservazione registrata, l'80% dei dati è stato destinato al training set e il restante 20% (le osservazioni più recenti) al test set, evitando così forme di data leakage.

L'addestramento impiega la stessa architettura per la rete ricorrente e gli stessi iperparametri per il modello di ML tradizionale utilizzati per i modelli generali in

4.1; i risultati sono riportati in Tabella 4.5.

Paziente <i>LIB193939</i>		
	Train (80%)	Test (20%)
# Record	21,680	5,421

Paziente <i>LIB194117</i>		
	Train (80%)	Test (20%)
# Record	12,101	3,026

Figura 4.2: Strategia di suddivisione per l'addestramento dei modelli personalizzati.

Tabella 4.5: Prestazioni del modello generale e personalizzato per i due pazienti considerati.

Modello	Paziente <i>LIB193939</i>			Paziente <i>LIB194117</i>		
	MAE	MAPE (%)	RMSE	MAE	MAPE (%)	RMSE
XGB (Generale)	9.13	9.60	12.24	17.71	13.43	24.51
XGB (Personalizzato)	8.08	8.18	11.63	18.82	14.35	25.62
GRU (Generale)	8.90	9.37	12.07	17.53	13.28	24.27
GRU (Personalizzato)	7.87	8.10	11.28	18.41	14.19	24.90

Gli esiti mostrano che, per il paziente *LIB193939* (il "migliore"), entrambi i modelli migliorano le prestazioni rispetto ai modelli generali. Al contrario, per *LIB194117* (il "peggiore") il modello personalizzato ottiene prestazioni inferiori. La valutazione clinica giunge alle stesse conclusioni: le percentuali nelle regioni della Clarke Error Grid (Tabelle 4.6 e 4.7) e le rappresentazioni grafiche in Figura 4.3 confermano l'andamento emerso dalle metriche statistiche.

Un'estensione dello studio ad altri pazienti permetterebbe considerazioni più robuste; tuttavia, da questi due casi emerge che:

1. per il paziente "peggiore", in cui ci si sarebbe attesi un guadagno dal modello personalizzato, il miglioramento non si è verificato;

Tabella 4.6: Distribuzione delle inferenze nelle regioni CEG per il paziente *LIB193939*.

Regione	XGB		GRU	
	Generale	Personalizzato	Generale	Personalizzato
A	89.71%	91.85%	89.89%	92.49%
B	8.43%	6.97%	8.15%	6.71%
C	0.00%	0.00%	0.00%	0.00%
D	1.86%	1.18%	1.96%	0.79%
E	0.00%	0.00%	0.00%	0.00%
Clinicamente accettabili (A+B)	98.14%	98.82%	98.04%	99.21%

Tabella 4.7: Distribuzione delle inferenze nelle regioni CEG per il paziente *LIB194117*.

Regione	XGB		GRU	
	Generale	Personalizzato	Generale	Personalizzato
A	79.11%	77.13%	80.17%	77.30%
B	17.38%	18.57%	16.59%	18.64%
C	0.20%	0.20%	0.17%	0.17%
D	3.30%	4.10%	3.07%	3.90%
E	0.00%	0.00%	0.00%	0.00%
Clinicamente accettabili (A+B)	96.50%	95.70%	96.76%	95.94%

2. il paziente "migliore", che ha beneficiato del personalizzato, presenta un range di valori glicemici più ristretto e un andamento più lineare: fattore che potrebbe aver favorito l'adattamento del modello.

Infine, in un contesto applicativo reale, un modello personalizzato risulta più oneroso da addestrare rispetto a un modello generale già pronto all'uso. Ciò suggerisce che il modello generale resti la scelta preferibile per praticità d'uso e accuratezza complessiva.

È quindi possibile fornire la risposta alla seconda Domanda di Ricerca.

🔗 **Answer to RQ₂.** Nei due casi analizzati, il modello personalizzato migliora per il paziente "migliore" e peggiora per il "peggiore". In sintesi, la differenza di performance non è sistematica e dipende dal profilo del paziente; a parità di accuratezza, il modello generale resta preferibile per praticità d'uso.




Figura 4.3: CEG a confronto per paziente e strategia di addestramento.

4.3 Interpretabilità con SHAP: evidenze globali e locali

Per interpretare le decisioni dei modelli è stato adottato *SHAP*, un metodo di Explainable Artificial Intelligence (XAI) che "spiega" le previsioni dei modelli di machine learning collegando la previsione ai contributi marginali locali, utilizzando i valori di Shapley della teoria dei giochi [34]. *SHAP* offre spiegazioni sia a livello globale (sull'intero dataset) sia a livello locale (sulla singola previsione), mostrando come ciascuna feature influenzi il risultato.

In pratica, con la tecnica SHAP si assegna a ogni feature un contributo additivo alla previsione corrente $f(x)$ rispetto a una previsione di base $E[f(X)]$. Per una certa istanza, si considerano tutti i possibili sottoinsiemi di feature: si misura quanto la previsione aumenta o diminuisce aggiungendo la feature i -esima a ciascun sottoinsieme che non la contiene, quindi si media tale contributo su tutti i sottoinsiemi. Il risultato è il valore di Shapley della feature, ossia il suo contributo medio alla previsione; la somma di tutti i valori di Shapley eguaglia esattamente $f(x) - E[f(X)]$.

- Nei *Summary Plot*, ogni punto mostra il contributo di una feature nella previsione di una singola istanza; il colore codifica se il valore della feature è alto o basso.
- Nei *Waterfall Plot*, si ricostruisce come ciascuna feature sposti l'output dal valore di base $E[f(X)]$ fino alla predizione finale $f(x)$.

Queste rappresentazioni rendono più agevole comprendere l'importanza delle variabili nelle previsioni del modello.

All'interno della libreria SHAP è stato impiegato il *TreeExplainer* per XGBoost e il *KernelExplainer* per la rete ricorrente GRU. Quest'ultimo è completamente *model-agnostic* e può essere applicato a qualsiasi modello. Poiché la nostra pipeline effettua la normalizzazione dei dati specificata dall'Equazione 3.3.1, i valori SHAP sono inizialmente calcolati nel range $[-1, 1]$. Per rendere i grafici più interpretabili, è stata quindi applicata la trasformazione inversa per riportare i contributi SHAP alla scala glicemica $[40, 400]$.

I Summary Plot in Figura 4.5 mostrano un quadro coerente tra i due modelli:

- lag0 e lag15 — i valori registrati nella mezz'ora precedente la predizione — risultano sistematicamente le feature più impattanti. Valori elevati di lag0 spingono la previsione verso glicemie più alte; i contributi di lag15 mostrano lo stesso comportamento, con maggiore dispersione dovuta al rumore.
- I lag meno recenti, da lag30 a lag105, hanno scarso impatto e si concentrano intorno allo zero. È tuttavia osservabile come lag45, per il modello XGBoost, segua un comportamento diverso rispetto alle altre feature: valori elevati tendono a ridurre la glicemia inferita.

La Figura 4.4 mostra infine che i due modelli hanno appreso in modo coerente le stesse importanze per le feature adottate.





Figura 4.4: Valore SHAP medio per feature per i due modelli rappresentativi.


I Waterfall Plot, visibili in Figura 4.6, confermano che le stesse feature identificate nell’analisi globale guidano casi clinici differenti: nei casi di iperglicemia e ipoglicemia, lag0 contribuisce rispettivamente in positivo (spinta verso valori alti) e in negativo (spinta verso valori bassi), mentre lag15 attenua o rafforza la salita o la discesa. Nei casi di normoglicemia, l’output resta vicino alla base $E[f(X)]$ e i contributi risultano più contenuti.

È quindi possibile fornire una risposta alla terza Domanda di Ricerca:

🔗 **Answer to RQ₃.** Le previsioni risultano spiegabili: globalmente, SHAP mostra che i modelli si basano soprattutto sul livello corrente di glicemia e sul trend degli ultimi 30 minuti; localmente, i Waterfall Plot confermano gli stessi contributi in condizioni di ipo-, normo- e iperglicemia. In definitiva, i grafici scelti forniscono spiegazioni comprensibili e coerenti con la fisiologia.



(a) XGBoost



(b) GRU

Figura 4.5: Summary Plot per i due modelli rappresentativi.




Figura 4.6: Waterfall Plot di GRU per tre casi clinici: iper-, normo- e ipoglicemia.

5.1 Risultati principali e impatto del lavoro

L'obiettivo generale era definire un quadro comparativo e riproducibile per la previsione glicemica a breve termine che coniugasse accuratezza, praticabilità operativa e trasparenza del modello.

Gli esperimenti sul dataset *T1DiabetesGranada* mostrano che sia gli approcci di machine learning tradizionale sia le reti neurali ricorrenti consentono previsioni affidabili per un orizzonte di 30 minuti. L'evidenza principale è che non è necessario ricorrere ad architetture complesse per ottenere stime accurate: il vantaggio delle reti neurali è reale ma contenuto. Considerate le ampie differenze in termini di complessità, tempo e costo computazionale richiesti, un modello XGBoost opportunamente ottimizzato risulta la scelta più adatta al contesto trattato. Ne consegue che, in assenza di vincoli specifici, i modelli tradizionali possono costituire un punto di partenza efficace anche su altri dataset analoghi.

Il confronto tra modelli generali e personalizzati indica che la personalizzazione non garantisce un miglioramento sistematico rispetto al modello generale; la convenienza dipende dal profilo del paziente e dalla disponibilità di storico. In prospettiva applicativa permane tuttavia una differenza marcata: i modelli generali possono

essere impiegati direttamente per qualsiasi paziente, senza una fase preventiva di addestramento, mentre i modelli personalizzati richiedono un numero elevato di misurazioni e risultano quindi poco praticabili per nuovi utenti privi di una lunga storia. Sebbene studi basati su modelli personalizzati possano conseguire risultati interessanti, l'impatto più significativo si misura nella trasferibilità alla pratica: da questo punto di vista, i modelli generali rappresentano una soluzione più utile e promettente.

Sul piano della trasparenza, le analisi XAI condotte con SHAP restituiscono un quadro coerente con la fisiologia: il livello glicemico corrente e il trend recente guidano le previsioni; le spiegazioni locali rimangono leggibili nelle diverse condizioni cliniche. Ciò supporta la verifica clinica delle stime e fornisce uno strumento di controllo per monitorare il comportamento del modello in produzione, contribuendo a rafforzare la fiducia di utilizzatori clinici e pazienti.

5.2 Limiti e sviluppi futuri

Lo studio presenta alcune limitazioni che delineano con chiarezza le priorità per il proseguimento della ricerca.

La prima riguarda l'orizzonte di previsione, fissato a 30 minuti, che non esplora scenari con orizzonti più lontani, dove pattern a medio-lungo termine diventano più rilevanti. Estendere l'orizzonte tra 60 e 120 minuti permetterebbe di valutare come evolvano accuratezza e sicurezza clinica e di verificare se il vantaggio delle ANN aumenti con la distanza temporale della previsione. Un orizzonte più ampio potrebbe inoltre modificare le spiegazioni fornite da SHAP, potenzialmente rendendole più informative.

La seconda concerne la personalizzazione dei modelli, valutata solo su alcuni casi estremi del dataset anziché su una coorte più ampia, principalmente a causa di vincoli di tempo e risorse computazionali. Estendere l'analisi a un numero maggiore di soggetti consentirebbe di evidenziare differenze più nette. Si potrebbe inoltre ampliare lo studio a modelli che adottano strategie basate sul clustering.

Sul fronte dell'interpretabilità, l'impiego prevalente di SHAP ha conferito coerenza fisiologica alle decisioni dei modelli, ma resta da ampliare il ventaglio di metodi

XAI da applicare per migliorare metriche consolidate dell'interpretabilità, come fedeltà e stabilità. Inoltre, studi di usabilità con professionisti clinici sono essenziali per misurare l'effettiva utilità percepita e l'affidabilità operativa.

Bibliografia

- [1] C. Rodríguez León *et al.*, “Intelligent monitoring of diabetes mellitus by means of mobile and wearable devices,” Ph.D. dissertation, Universidad de Granada, 2025. (Citato alle pagine iii, 9, 10, 11, 12, 17 e 24)
- [2] C. Rodriguez-Leon, M. D. Aviles-Perez, O. Banos, M. Quesada-Charneco, P. J. Lopez-Ibarra Lozano, C. Villalonga, and M. Munoz-Torres, “T1diabetesgranada: a longitudinal multi-modal dataset of type 1 diabetes mellitus,” *Scientific Data*, vol. 10, no. 1, p. 916, 2023. (Citato alle pagine iii, 8, 20, 21 e 34)
- [3] H. Nemat, H. Khadem, J. Elliott, and M. Benaissa, “Data-driven blood glucose level prediction in type 1 diabetes: a comprehensive comparative analysis,” *Scientific reports*, vol. 14, no. 1, p. 21863, 2024. (Citato alle pagine 1 e 6)
- [4] S. S. Band, A. Yarahmadi, C.-C. Hsu, M. Biyari, M. Sookhak, R. Ameri, I. Dehzan-gi, A. T. Chronopoulos, and H.-W. Liang, “Application of explainable artificial intelligence in medical health: A systematic review of interpretability methods,” *Informatics in Medicine Unlocked*, vol. 40, p. 101286, 2023. (Citato a pagina 2)
- [5] J. Yang, L. Li, Y. Shi, and X. Xie, “An arima model with adaptive orders for predicting blood glucose concentrations and hypoglycemia,” *IEEE journal of biomedical and health informatics*, vol. 23, no. 3, pp. 1251–1260, 2018. (Citato a pagina 6)

-
- [6] F. Prendin, S. Del Favero, M. Vettoretti, G. Sparacino, and A. Facchinetti, "Forecasting of glucose levels and hypoglycemic events: head-to-head comparison of linear and nonlinear data-driven algorithms based on continuous glucose monitoring data only," *Sensors*, vol. 21, no. 5, p. 1647, 2021. (Citato a pagina 6)
- [7] A. Z. Woldaregay, E. Årsand, S. Walderhaug, D. Albers, L. Mamykina, T. Botsis, and G. Hartvigsen, "Data-driven modeling and prediction of blood glucose dynamics: Machine learning applications in type 1 diabetes," *Artificial intelligence in medicine*, vol. 98, pp. 109–134, 2019. (Citato a pagina 6)
- [8] R. Bunescu, N. Struble, C. Marling, J. Shubrook, and F. Schwartz, "Blood glucose level prediction using physiological models and support vector regression," in *2013 12th International Conference on Machine Learning and Applications*, vol. 1. IEEE, 2013, pp. 135–140. (Citato a pagina 6)
- [9] V. B. Berikov, O. A. Kutnenko, J. F. Semenova, and V. V. Klimontov, "Machine learning models for nocturnal hypoglycemia prediction in hospitalized patients with type 1 diabetes," *Journal of Personalized Medicine*, vol. 12, no. 8, p. 1262, 2022. (Citato a pagina 6)
- [10] W. P. Van Doorn, Y. D. Foreman, N. C. Schaper, H. H. Savelberg, A. Koster, C. J. van der Kallen, A. Wesselius, M. T. Schram, R. M. Henry, P. C. Dagnelie *et al.*, "Machine learning-based glucose prediction with use of continuous glucose and physical activity monitoring data: The maastricht study," *PloS one*, vol. 16, no. 6, p. e0253125, 2021. (Citato alle pagine 6 e 7)
- [11] Y. Bengio, P. Simard, and P. Frasconi, "Learning long-term dependencies with gradient descent is difficult," *IEEE transactions on neural networks*, vol. 5, no. 2, pp. 157–166, 1994. (Citato a pagina 7)
- [12] S. Mirshekarian, H. Shen, R. Bunescu, and C. Marling, "Lstms and neural attention models for blood glucose prediction: Comparative experiments on real and synthetic data," in *2019 41st annual international conference of the IEEE engineering in medicine and biology society (EMBC)*. IEEE, 2019, pp. 706–712. (Citato a pagina 7)

-
- [13] K. Li, J. Daniels, C. Liu, P. Herrero, and P. Georgiou, "Convolutional recurrent neural networks for glucose prediction," *IEEE journal of biomedical and health informatics*, vol. 24, no. 2, pp. 603–613, 2019. (Citato a pagina 7)
- [14] H. Nemat, H. Khadem, J. Elliott, and M. Benaissa, "Data fusion of activity and cgm for predicting blood glucose levels," in *Knowledge Discovery in Healthcare Data 2020*, vol. 2675. CEUR Workshop Proceedings, 2020, pp. 120–124. (Citato a pagina 7)
- [15] H. Khadem, H. Nemat, J. Elliott, and M. Benaissa, "Multi-lag stacking for blood glucose level prediction," in *Knowledge Discovery in Healthcare Data 2020*, vol. 2675. CEUR-Workshop Proceedings, 2020, pp. 146–150. (Citato a pagina 7)
- [16] J. Martinsson, A. Schliep, B. Eliasson, and O. Mogren, "Blood glucose prediction with variance estimation using recurrent neural networks," *Journal of Healthcare Informatics Research*, vol. 4, no. 1, pp. 1–18, 2020. (Citato a pagina 7)
- [17] T. Hamdi, J. B. Ali, V. Di Costanzo, F. Fnaiech, E. Moreau, and J.-M. Ginoux, "Accurate prediction of continuous blood glucose based on support vector regression and differential evolution algorithm," *Biocybernetics and Biomedical Engineering*, vol. 38, no. 2, pp. 362–372, 2018. (Citato a pagina 7)
- [18] J. B. Ali, T. Hamdi, N. Fnaiech, V. Di Costanzo, F. Fnaiech, and J.-M. Ginoux, "Continuous blood glucose level prediction of type 1 diabetes based on artificial neural network," *Biocybernetics and Biomedical Engineering*, vol. 38, no. 4, pp. 828–840, 2018. (Citato a pagina 7)
- [19] S. Mirshekarian, R. Bunescu, C. Marling, and F. Schwartz, "Using lstms to learn physiological models of blood glucose behavior," in *2017 39th Annual international conference of the IEEE engineering in medicine and biology society (EMBC)*. IEEE, 2017, pp. 2887–2891. (Citato a pagina 7)
- [20] A. Güemes, G. Cappon, B. Hernandez, M. Reddy, N. Oliver, P. Georgiou, and P. Herrero, "Predicting quality of overnight glycaemic control in type 1 diabetes using binary classifiers," *IEEE journal of biomedical and health informatics*, vol. 24, no. 5, pp. 1439–1446, 2019. (Citato a pagina 7)

- [21] C. Zecchin, A. Facchinetti, G. Sparacino, and C. Cobelli, "How much is short-term glucose prediction in type 1 diabetes improved by adding insulin delivery and meal content information to cgm data? a proof-of-concept study," *Journal of diabetes science and technology*, vol. 10, no. 5, pp. 1149–1160, 2016. (Citato a pagina 7)
- [22] M. S. M. Nordin and F. Mahmud, "Univariate and multivariate time series blood glucose prediction with lstm deep learning model," *Evolution in Electrical and Electronic Engineering*, vol. 5, no. 1, pp. 276–285, 2024. (Citato a pagina 7)
- [23] H. Hameed and S. Kleinberg, "Comparing machine learning techniques for blood glucose forecasting using free-living and patient generated data," in *Machine Learning for Healthcare Conference*. PMLR, 2020, pp. 871–894. (Citato a pagina 7)
- [24] C. D. Man, F. Micheletto, D. Lv, M. Breton, B. Kovatchev, and C. Cobelli, "The uva/padova type 1 diabetes simulator: new features," *Journal of diabetes science and technology*, vol. 8, no. 1, pp. 26–34, 2014. (Citato a pagina 8)
- [25] V. Felizardo, N. M. Garcia, N. Pombo, and I. Megdiche, "Data-based algorithms and models using diabetics real data for blood glucose and hypoglycaemia prediction—a systematic literature review," *Artificial intelligence in medicine*, vol. 118, p. 102120, 2021. (Citato a pagina 8)
- [26] C. Marling and R. Bunescu, "The ohiot1dm dataset for blood glucose level prediction: Update 2020," in *CEUR workshop proceedings*, vol. 2675, 2020, p. 71. (Citato a pagina 8)
- [27] "The 3rd international workshop on knowledge discovery in healthcare data," <https://sites.google.com/view/kdhd-2018/bglp-challenge>. (Citato alle pagine 8 e 24)
- [28] "The 5th international workshop on knowledge discovery in healthcare data," <https://sites.google.com/view/kdh-2020/bglp-challenge>. (Citato alle pagine 8, 10 e 24)

-
- [29] T. Prioleau, A. Bartolome, R. Comi, and C. Stanger, "Diatrend: A dataset from advanced diabetes technology to enable development of novel analytic solutions," *Scientific Data*, vol. 10, no. 1, p. 556, 2023. (Citato a pagina 8)
- [30] G. Annuzzi, A. Apicella, P. Arpaia, L. Bozzetto, S. Criscuolo, E. De Benedetto, M. Pesola, and R. Prevete, "Exploring nutritional influence on blood glucose forecasting for type 1 diabetes using explainable ai," *IEEE journal of biomedical and health informatics*, vol. 28, no. 5, pp. 3123–3133, 2023. (Citato a pagina 9)
- [31] F. Prendin, J. Pavan, G. Cappon, S. Del Favero, G. Sparacino, and A. Facchinetti, "The importance of interpreting machine learning models for blood glucose prediction in diabetes: an analysis using shap," *Scientific reports*, vol. 13, no. 1, p. 16865, 2023. (Citato a pagina 9)
- [32] M. Medicine, "High blood sugar (hyperglycemia)," <https://www.med.umich.edu/1libr/MEND/Diabetes-Hyperglycemia.pdf>. (Citato a pagina 22)
- [33] S. J. Chu, N. Amarasiri, S. Giri, and P. Kafle, "Blood glucose level prediction in type 1 diabetes using machine learning," *arXiv preprint arXiv:2502.00065*, 2025. (Citato alle pagine 25 e 29)
- [34] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," *Advances in neural information processing systems*, vol. 30, 2017. (Citato a pagina 45)